

Análise de Gravidade de Sinistros nas Rodovias Federais Brasileiras

Davi da Silva Romão¹, Diogo Talys da Mota Amorim¹,
Gabriel Gomes de Oliveira¹, Thiago Ribeiro da Silva¹

¹ Instituto de Computação – Universidade Federal de Alagoas (UFAL)
Maceió – AL – Brasil

{dsr, dtma, ggo, trs}@ic.ufal.br

Abstract. *This work analyzes 300,086 records of traffic accidents on Brazilian federal highways between 2022 and 2026, aiming to identify the combinations of temporal, spatial, causal, and infrastructural factors associated with accident severity. After data cleaning and feature engineering, bivariate association tests, odds ratio analysis, STL time-series decomposition, and spatial concentration analysis via the Lorenz curve were applied to verify five hypotheses. Results show that accident type is the strongest individual predictor of fatality (Cramér's $V = 0.344$); roundabouts present the highest protective effect among road geometry attributes ($OR = 0.287$); weekend trips increase fatal proportions regardless of traffic volume ($RR = 1.256$); 13.9% of the road network concentrates 50% of fatal incidents; and regional fatality rates are significantly associated with single-lane road density ($\chi^2 = 2023.65$, $p < 0.001$), with North and Northeast regions exhibiting twice the fatality rate of South and Southeast regions. The findings provide quantitative support for resource allocation decisions by road safety agencies.*

Resumo. *Este trabalho analisa 300.086 registros de sinistros de trânsito ocorridos nas rodovias federais brasileiras entre 2022 e 2026, com o objetivo de identificar combinações de fatores temporais, espaciais, causais e infraestruturais associadas à gravidade das ocorrências. Após limpeza e engenharia de features, aplicamos testes de associação bivariada, análise de razão de chances, decomposição STL e análise de concentração espacial via curva de Lorenz para verificar cinco hipóteses. Os resultados mostram que o tipo de acidente é o preditor individual mais relevante (V de Cramér = 0,344); rotatórias apresentam o maior efeito protetor entre os atributos de traçado ($OR = 0,287$); fins de semana elevam a proporção fatal independentemente do volume de tráfego ($RR = 1,256$); 13,9% da malha concentra 50% dos fatais; e as taxas de fatalidade regionais estão significativamente associadas à densidade de pistas simples ($\chi^2 = 2023,65$, $p < 0,001$), com as regiões Norte e Nordeste registrando taxas de fatalidade duas vezes superiores às das regiões Sul e Sudeste. Os achados fornecem suporte quantitativo para decisões de alocação de recursos por órgãos de segurança viária.*

1. Introdução

Todo ano, os acidentes em rodovias federais brasileiras consomem recursos de saúde, reduzem a produtividade e deixam sequelas permanentes em famílias. Diante desse cenário, a Polícia Rodoviária Federal (PRF) e o Departamento Nacional de Infraestrutura de Transportes (DNIT) precisam decidir onde, quando e como atuar. Este trabalho examina 300.086 registros de sinistros entre 2022 e 2026 para identificar quais combinações de fatores temporais, espaciais, meteorológicos, causais e infraestruturais elevam a probabilidade de morte. O objetivo é subsidiar três decisões práticas: alocação de efetivo, priorização de obras e dimensionamento de resposta emergencial.

As hipóteses investigadas são:

- H1** Causas comportamentais (ingestão de álcool, uso de substâncias psicoativas e sono ao volante) ocorrem com maior frequência no período noturno e estão associadas a maior gravidade do sinistro em comparação com outras causas no mesmo horário.
- H2** Fins de semana, feriados e períodos de férias concentram maior frequência absoluta e maior proporção de sinistros com vítimas fatais, refletindo padrões de tráfego intenso e comportamento de risco.
- H3** Condições meteorológicas adversas têm impacto diferenciado sobre a gravidade dos sinistros dependendo da região do país.
- H4** A distribuição dos sinistros não é uniforme: trechos específicos de rodovias concentram parcela desproporcional das ocorrências fatais.
- H5** O perfil de gravidade dos sinistros difere entre as cinco regiões brasileiras, com regiões de maior extensão de pista simples apresentando taxas de fatalidade superiores às de maior infraestrutura duplicada.

2. Base de Dados

2.1. Descrição da Base

A base utilizada é o conjunto de dados de sinistros de trânsito agrupados por ocorrência, disponibilizado publicamente pela Polícia Rodoviária Federal (PRF) no Portal de Dados Abertos do Governo Federal [Polícia Rodoviária Federal 2024a]. Os registros derivam do Boletim de Acidente de Trânsito (BAT), com atualização mensal e série histórica desde 2007. O recorte temporal adotado compreende os anos de 2022 a 2026; o limite inferior foi definido para eliminar o viés pandêmico de 2020 e 2021, período em que a redução artificial do volume de tráfego distorce análises de tendência e sazonalidade. Com esse recorte, a base bruta totaliza **301.532 registros**, organizados em cinco dimensões principais: variáveis temporais (data, horário, dia da semana), espaciais (UF, município, rodovia, quilometragem e coordenadas geográficas), causais (causa e tipo de acidente e classificação de gravidade), infraestruturais (condição meteorológica, tipo e traçado da pista, uso do solo) e de consequências (mortos, feridos leves, feridos graves e ileso).

2.2. Análise Estrutural e Limpeza dos Dados

A base bruta passou por um processo de limpeza estruturado em cinco etapas: (i) remoção das colunas `regional`, `delegacia` e `uop`, que contêm metadados administrativos internos com inconsistências geográficas; (ii) exclusão da coluna `id` e de 6 registros duplicados por ela mascarados; (iii) correção da tipagem das variáveis

km, latitude e longitude (strings com vírgula convertidas para float) e correção ortográfica de `condicao_meteorologica`; (iv) exclusão de 5 registros nulos em `classificacao_acidente` (análise de sensibilidade indicou impacto máximo de 0,0017 p.p., inferior ao erro padrão SE = 0,055 p.p.); e (v) remoção de 1.435 registros com km = 0 (756 registros anômalos com br = 0 e `sentido_via` nulo, validados por IC de Wilson 95% [Wilson 1927], e 679 registros violando a especificação posicional mínima da PRF de 0,1 km [Polícia Rodoviária Federal 2024b], cuja imputação geraria ruído espacial). Após a limpeza, a base resultante totalizou **300.086 registros**.

2.3. Engenharia de Features

A partir da base limpa, foram criadas variáveis para enriquecer a representação temporal, espacial e causal dos sinistros.

As colunas `data_inversa` e `horario` foram combinadas em `data_hora`, a partir da qual se extraíram faixas horárias (madrugada, manhã, tarde, noite), mês, estação do ano (hemisfério sul), e indicadores binários de fim de semana e feriado nacional — incluindo feriados móveis (Carnaval, Sexta-Feira Santa, Corpus Christi) calculados via data da Páscoa. A variável `tracado_via`, que armazenava múltiplas características separadas por ponto e vírgula, foi decomposta em 12 binárias independentes por codificação *multilabel*.

A variável `causa_acidente` apresentava 76 categorias, das quais 76,3% representavam individualmente menos de 1% dos registros, caracterizando distribuição altamente esparsa. As causas foram consolidadas em 8 grupos por similaridade semântica observada: falha de atenção e reação, infração e comportamento de risco, falha mecânica, infraestrutura e sinalização, condição ambiental, obstrução da via, condição de saúde do condutor e envolvimento de pedestre. Após a consolidação, nenhum grupo ficou abaixo de 0,5% dos registros.

A variável `km` foi discretizada em faixas de 5 km. A comparação entre tamanhos de *bucket* revelou retornos decrescentes: a transição de 1 para 5 km ganha 6,1 p.p. na proporção de intervalos com suporte adequado (≥ 30 registros), enquanto os passos seguintes rendem apenas 3,6 e 1,8 p.p. a custo de metade da resolução espacial. O bucket de 5 km representa o ponto de inflexão, resultando em 254 intervalos com 82,3% de cobertura adequada. Por fim, `uf` foi mapeada para região geográfica brasileira. O conjunto completo está descrito na Tabela 1.

3. Estatística Descritiva e Inferência

3.1. Variável-Alvo

A variável `classificacao_acidente` apresenta três classes ordinais de gravidade crescente: *Sem Vítimas* (15,9%), *Com Vítimas Feridas* (73,8%) e *Com Vítimas Fatais* (10,3%). A distribuição é desequilibrada: a classe majoritária é 7,17 vezes mais frequente que a minoritária. Para uma medida mais informativa do desbalanceamento no problema triclasse, calculamos a entropia de Shannon normalizada, dada por $H' = -\sum_k p_k \log_2 p_k / \log_2 K$, onde $K = 3$ é o número de classes. O valor obtido, $H' = 0,683$, indica que a distribuição possui apenas 68,3% da entropia máxima possível para três classes equiprováveis [Shannon 1948], refletindo a concentração em *Com Vítimas*

Tabela 1. Variáveis criadas na etapa de engenharia de features.

Variável	Tipo	Descrição
<code>data_hora</code>	datetime	Combinação de <code>data_inversa</code> e <code>horario</code> em timestamp unificado
<code>horario</code>	categórica	Faixa horária: Madrugada (0–6h), Manhã (6–12h), Tarde (12–18h), Noite (18–24h)
<code>mes</code>	numérica	Mês de ocorrência extraído de <code>data_hora</code> (1–12)
<code>estacao</code>	categórica	Estação do ano (hemisfério sul): Verão, Outono, Inverno, Primavera
<code>fim_de_semana</code>	binária	1 se o sinistro ocorreu em sábado ou domingo; 0 caso contrário
<code>feriado_nacional</code>	binária	1 se a data corresponde a feriado nacional fixo ou móvel; 0 caso contrário
<code>regiao</code>	categórica	Região geográfica derivada de <code>uf</code> (Norte, Nordeste, Centro-Oeste, Sudeste, Sul)
<code>faixa_km</code>	numérica	Discretização de <code>km</code> em intervalos de 5 km
<code>causa_acidente_grupo</code>	categórica	Agrupamento semântico das 76 causas originais em 8 grupos temáticos
<code>tr_[tipo]</code>	binária	12 variáveis indicando presença de cada característica de traçado (ex.: <code>tr_curva</code> , <code>tr_ponte</code>)
<code>n_caract_tracado</code>	numérica	Total de características simultâneas de traçado por registro

Feridas. A classe de maior interesse preditivo — *Com Vítimas Fatais* — é justamente a menos representada, exigindo tratamento específico na etapa de modelagem.

3.2. Variáveis Categóricas

A força de associação entre cada variável categórica e a variável-alvo foi quantificada pelo V de Cramér com correção de viés [Bergsma 2013], precedido pelo teste qui-quadrado de independência [Pearson 1900]. Com $n = 300.086$ registros, o p -valor tende a rejeitar H_0 para qualquer associação não nula, tornando o tamanho do efeito a métrica relevante. Os resultados estão na Tabela 2, com interpretação segundo [Cohen 1988].

Nenhuma variável sozinha explica bem a gravidade dos acidentes. Isso era esperado, pois a fatalidade depende de vários fatores simultâneos. A única exceção é `tipo_acidente`, com V de Cramér de 0,344, um efeito moderado que mostra como o formato da colisão influencia a chance de morte. Todos os outros preditores isolados são fracos ou irrelevantes. Por isso, modelos que capturam interações entre variáveis são mais promissores do que análises bivariadas.

3.3. Variáveis Numéricas

A Tabela 3 reúne as estatísticas descritivas das variáveis numéricas. Todas exibem assimetria positiva acentuada (skewness de 0,998 a 13,256) e curtose elevada, indicando caudas pesadas com eventos extremos pouco frequentes. As variáveis de contagem de vítimas apresentam forte inflação em zero: 92,8% dos registros não têm mortos e 77,3%

Tabela 2. Associação entre variáveis categóricas e `classificacao_acidente` (V de Cramér com correção de viés).

Variável	χ^2	V de Cramér	Interpretação
<code>tipo_acidente</code>	71.282	0,3446	Moderada
<code>causa_acidente_grupo</code>	20.181	0,1833	Fraca
<code>horario</code>	6.200	0,1016	Fraca
<code>uso_solo</code>	2.854	0,0975	Negligenciável
<code>regiao</code>	3.410	0,0753	Negligenciável
<code>tipo_pista</code>	3.234	0,0734	Negligenciável
<code>dia_semana</code>	1.325	0,0468	Negligenciável
<code>condicao_meteorologica</code>	587	0,0308	Negligenciável
<code>sentido_via</code>	38	0,0109	Negligenciável
<code>estacao</code>	34	0,0068	Negligenciável

Tabela 3. Estatísticas descritivas das variáveis numéricas.

Variável	Média	Mediana	DP	Assim.	Curtose	% zero
<code>km</code>	260,5	195,0	226,7	0,998	0,348	0,00
<code>pessoas</code>	2,6	2,0	2,2	11,275	231,995	0,00
<code>mortos</code>	0,08	0,0	0,34	10,802	572,246	92,83
<code>feridos_leves</code>	0,87	1,0	1,09	9,960	336,963	37,20
<code>feridos_graves</code>	0,28	0,0	0,62	6,437	163,537	77,29
<code>ilesos</code>	1,05	1,0	1,77	13,256	321,323	38,08
<code>veiculos</code>	1,99	2,0	1,13	8,844	673,030	0,00
<code>n_caract_tracado</code>	1,25	1,0	0,50	2,105	6,068	0,00

não têm feridos graves, o que reflete a predominância de sinistros sem vítimas fatais na base. A inspeção via gráfico quantil-quantil (QQ-plot) confirmou desvios substanciais da normalidade em todas as variáveis.

Essas características inviabilizam a suposição de normalidade necessária para testes paramétricos. Optou-se, portanto, pelo teste de Kruskal-Wallis [Kruskal and Wallis 1952] para avaliar associação com a variável-alvo. O tamanho do efeito foi expresso pelo épsilon-quadrado (ϵ^2) [Tomczak and Tomczak 2014]. O número de veículos envolvidos apresentou efeito pequeno ($H = 5522$; $\epsilon^2 = 0,0184$), enquanto `n_caract_tracado` ($H = 171$; $\epsilon^2 = 0,0006$) e `mes` ($H = 2,85$; $p = 0,241$; não significativo) apresentaram efeitos negligenciáveis.

3.4. Variáveis Binárias de Traçado Viário

A associação das variáveis binárias de traçado com a ocorrência de acidente fatal foi quantificada pela Razão de Chances (OR) com intervalo de confiança de 95% e correção de Haldane-Anscombe. Os resultados estão apresentados na Tabela 4.

Pontes (OR = 1,501; IC 95% [1,339; 1,682]) e declives (OR = 1,489; IC 95% [1,430; 1,550]) são os traçados com maior associação positiva com fatalidade, seguidos de aclives e curvas. No extremo oposto, rotatórias apresentam o efeito protetor mais expressivo da análise (OR = 0,287; IC 95% [0,246; 0,335]), associadas a uma redução

Tabela 4. Razão de Chances (OR) para ocorrência de acidente fatal por característica de traçado viário.

Variável	OR	IC 95%	Aumenta risco
tr_ponte	1,501	[1,339; 1,682]	Sim
tr_declive	1,489	[1,430; 1,550]	Sim
tr_aclive	1,279	[1,220; 1,341]	Sim
tr_curva	1,159	[1,120; 1,200]	Sim
tr_reta	1,133	[1,098; 1,170]	Sim
tr_em_obras	0,885	[0,799; 0,980]	Não
tr_desvio_temporario	0,770	[0,610; 0,972]	Não
tr_viaduto	0,547	[0,474; 0,631]	Não
tr_intersecao_de_vias	0,454	[0,421; 0,489]	Não
tr_retorno_regulament	0,440	[0,387; 0,500]	Não
tr_rotatoria	0,287	[0,246; 0,335]	Não

de aproximadamente 71% na chance de acidente fatal em relação a trechos sem essa característica. A variável `tr_tunel` não apresentou associação significativa (IC 95% inclui 1), o que pode refletir o tamanho reduzido da amostra para esse traçado ($n = 178$).

Essa assimetria tem explicação no comportamento do tráfego. Pontes, declives e curvas exigem velocidade e oferecem pouca margem de erro. Rotatórias, retornos e interseções, por outro lado, forcem a redução de velocidade e concentram a atenção do motorista.

3.5. Síntese da Análise de Associação

A análise bivariada confirma que nenhuma variável isolada determina a gravidade dos sinistros. `tipo_acidente` é o preditor individual de maior relevância ($V = 0,344$), seguido por `causa_acidente_grupo` ($V = 0,183$). As variáveis temporais e meteorológicas apresentam efeitos fracos a negligenciáveis, sugerindo que sua influência se manifesta principalmente em interação com outros fatores. A não significância de `mes` no teste de Kruskal-Wallis é um resultado relevante: a sazonalidade parece ser um fenômeno de volume de sinistros, não de gravidade, o que tem implicações diretas para a interpretação de H_2 .

3.6. Verificação das Hipóteses

3.6.1. H1 — Causas Comportamentais e Período Noturno

A verificação de H_1 operacionalizou “causas comportamentais” a partir das causas individuais de `causa_acidente`, não do agrupamento semântico, por ser este último genérico demais para a hipótese. As causas selecionadas foram: *Condutor Dormindo*, *Ingestão de álcool pelo condutor*, *Ingestão de substâncias psicoativas pelo condutor* e *Velocidade Incompatível*, totalizando 44.867 registros (15,0% da base).

H1a — concentração noturna. O teste qui-quadrado entre a flag comportamental e a faixa horária resultou em $\chi^2 = 8029,3$ ($p < 0,001$; $V = 0,164$), confirmando associação fraca mas consistente. Causas comportamentais concentram proporcional-

mente mais ocorrências na madrugada e à noite do que causas de outras naturezas, o que é coerente com os padrões de uso de substâncias e fadiga ao longo do dia.

H1b — maior gravidade noturna. O resultado contraria a formulação original da hipótese. O OR calculado para o período noturno foi de 0,662 (IC 95% [0,629; 0,698]), indicando que, à noite, causas comportamentais estão associadas a *menor* chance de desfecho fatal em comparação com outras causas no mesmo período. Já no período diurno, o OR é de 1,280 (IC 95% [1,205; 1,359]), com sentido oposto: de dia, causas comportamentais são mais letais que as demais.

Esse padrão reflete a composição do grupo de controle. À noite, acidentes não comportamentais envolvem colisões frontais em alta velocidade, atropelamentos e saídas de pista. São eventos graves por natureza, o que eleva a linha de base e faz o OR comportamental parecer menor. De dia, a concorrência é de engavetamentos e colisões de baixa energia, então o mesmo comportamento de risco se destaca como mais letal. O OR global de 0,949 (IC 95% [0,912; 0,987]) indica que, em média, causas comportamentais são ligeiramente menos letais que o restante — resultado que só faz sentido à luz da estratificação horária, visualizada na Figura 1.

H1 é parcialmente confirmada: H1a é confirmada (concentração noturna das causas comportamentais, $V = 0,164$, $p < 0,001$); H1b é refutada na direção esperada — a gravidade é maior de dia, não à noite.




Figura 1. Taxa de fatalidade por grupo de causa (comportamental vs. demais) e período do dia. De dia, causas comportamentais são relativamente mais letais; à noite, o grupo de referência — colisões frontais e atropelamentos — deprime o OR comportamental por contraste.

3.6.2. H2 — Sazonalidade e Fins de Semana

A decomposição STL da série mensal de sinistros revelou que a componente sazonal explica 38,2% da variância do volume de ocorrências e 67,1% da variância da proporção

fatal mensal. A gravidade tem sazonalidade mais forte que o volume. Isso significa que os meses com mais acidentes não são os meses com mais mortes: os dois ciclos estão desalinhados. Esse resultado refina o p-valor não significativo obtido para *mes* no Kruskal-Wallis ($p = 0,241$): o mês isolado não prediz a classe, mas a proporção fatal segue um padrão temporal regular quando analisada em série.

A comparação de proporções por recorte temporal, via teste z de duas proporções, produziu resultados heterogêneos entre os subgrupos de H2. Fins de semana apresentaram o efeito mais robusto: 8,32% de proporção fatal contra 6,62% nos demais dias (RR = 1,256; $z = 16,84$; $p < 0,001$). Feriados nacionais também elevam a proporção, porém com magnitude menor: 7,84% contra 7,15% (RR = 1,097; $z = 2,68$; $p = 0,007$). O período de férias (janeiro, julho e dezembro), por sua vez, não apresentou diferença significativa na proporção fatal: 7,22% contra 7,16% (RR = 1,008; $p = 0,594$) — o volume de sinistros aumenta, mas o perfil de gravidade não muda.

H2 é parcialmente confirmada. Fins de semana e feriados elevam a proporção de fatalidade, mas férias não. Os dados sugerem que o risco adicional nos fins de semana reflete o perfil comportamental dos deslocamentos, não o volume de tráfego.




Figura 2. Componente sazonal normalizada (STL) do volume mensal de sinistros e da proporção fatal mensal. Ciclos independentes indicam que a sazonalidade de volume e de gravidade operam em defasagem.

3.6.3. H3 — Condições Meteorológicas por Região

A análise classificou como adversas as condições: Chuva, Garoa/Chuvisco, Granizo, Neve, Nevoeiro/Neblina, Tempestade e Vento. As demais (Céu Claro, Nublado, Sol) foram tratadas como favoráveis.

H3a — efeito global. Contrariando a hipótese, condições meteorológicas adversas estão associadas a *menor* taxa de fatalidade: 6,47% contra 7,30% em condições favoráveis (OR = 0,879; IC 95% [0,844; 0,915]; $\chi^2 = 38,6$; $p < 0,001$; $V = 0,011$). O efeito global é estatisticamente significativo, mas de magnitude negligenciável. Esse resultado é consistente com o fenômeno de *risk compensation* documentado na literatura de segurança viária [Elvik et al. 2009]: em condições adversas, os condutores tendem a reduzir a velocidade e aumentar a distância de segurança, de modo que os acidentes resul-

tantes, embora mais frequentes em termos relativos ao volume de tráfego, são em média menos graves do que aqueles em dias de boas condições.

H3b — heterogeneidade regional. Os ORs regionais variam de 0,919 (Sudeste) a 0,978 (Sul), com amplitude de apenas 0,060. Nenhuma região apresentou OR significativo após correção de Bonferroni ($k = 5$): o menor p-valor ajustado foi 0,163, obtido para o Sudeste. O efeito é homogêneo entre regiões.

H3 é refutada. Condições meteorológicas adversas não apenas não elevam a gravidade dos sinistros como apresentam efeito protetor leve e uniforme entre regiões. O resultado sugere que o fator meteorológico atua via comportamento dos condutores, não via condições físicas da via, e que esse mecanismo opera de forma semelhante em todo o país.

3.6.4. H4 — Concentração Espacial

A distribuição de sinistros fatais por faixa de 5 km foi analisada pela curva de Lorenz, que quantifica a desigualdade entre a proporção acumulada de trechos e a proporção acumulada de ocorrências fatais. Os indicadores de concentração mostram forte assimetria: os 5% dos trechos com maior número de sinistros fatais concentram 26,6% das ocorrências, os 10% mais críticos acumulam 41,3%, e apenas 13,9% da malha responde por metade de todos os registros fatais.

Os dez trechos mais críticos (faixas de 5 km) são liderados por SP – BR-381 (km 85) com 38 sinistros fatais em quatro anos, seguido de SP – BR-116 (km 225) com 33. A BR-381 em SP aparece em duas faixas consecutivas (km 80 e km 85), totalizando 63 ocorrências em um corredor de 10 km. A BR-116 acumula três configurando esses eixos como os de maior concentração estrutural de fatalidades na malha federal.

H4 é confirmada. A distribuição espacial de sinistros fatais é altamente não uniforme: uma fração pequena da malha concentra parcela desproporcional das ocorrências, o que sustenta a adoção de critérios geográficos de priorização de fiscalização e intervenções de infraestrutura.




Figura 3. Curva de Lorenz espacial (faixas de 5 km) e ranking dos dez trechos com maior número de sinistros fatais no período 2022–2026.

3.6.5. H5 — Heterogeneidade Regional

A verificação de H5 avaliou a associação entre a severidade dos acidentes, as regiões brasileiras e a infraestrutura viária (tipo de pista). O teste qui-quadrado de independência confirmou que a gravidade dos sinistros difere significativamente entre as cinco regiões ($\chi^2 = 2023,65$; $p < 0,001$; $V = 0,082$). A análise de cruzamento de dados revela que a taxa de fatalidade em pistas simples (9,88%) é mais do que o dobro da registrada em pistas duplas (4,71%) e múltiplas (4,19%). A letalidade regional acompanha diretamente a proporção de pista simples de cada malha: as regiões Norte (69,90% de pista simples nos sinistros) e Nordeste (55,52%) registraram as maiores taxas de fatalidade (11,02% e 10,33%, respectivamente). Em contraste, o Sudeste, com apenas 40,43% de seus acidentes em pista simples, registrou uma taxa de fatalidade de 5,74%. Os testes post-hoc pairwise com correção de Bonferroni ($k = 10$) indicaram que as diferenças de letalidade entre as regiões são estatisticamente significativas ($p_{adj} < 0,05$), com exceção das comparações Sul–Sudeste ($p_{adj} = 0,182$) e Norte–Nordeste ($p_{adj} = 0,111$). Assim, H5 é confirmada, evidenciando que a precariedade da infraestrutura regional (predomínio de pistas simples) atua como um fator estrutural de agravamento da letalidade.




Figura 4. Taxa de fatalidade por região geográfica e tipo de pista. Regiões ordenadas da maior para a menor taxa agregada.

4. Métodos e Métricas de Avaliação

Para avaliar as hipóteses formuladas, usamos abordagens complementares de análise temporal, espacial e de associação bivariada. Como as variáveis numéricas não seguem distribuição normal (assimetria confirmada por QQ-plot em todas elas), optamos por testes não paramétricos ao longo de toda a análise.

4.1. Decomposição Temporal (STL)

A análise temporal de H2 baseou-se na decomposição STL (*Seasonal and Trend decomposition using Loess*) [Cleveland et al. 1990], parametrizada com período de 12 meses. O método separa a série mensal de sinistros em tendência, componente sazonal e resíduo.

Para distinguir efeitos de volume e severidade, aplicamos a decomposição de forma independente sobre a série de volume de sinistros e sobre a série da proporção mensal de acidentes fatais. A métrica principal de avaliação foi a proporção da variância total explicada pela componente sazonal em cada série. Adicionalmente, aplicamos o teste z de duas proporções para comparar a letalidade em recortes temporais específicos (fins de semana, feriados e férias).

4.2. Concentração Espacial (Curva de Lorenz)

Para testar a H4 (concentração espacial de fatalidades), calculamos a curva de Lorenz sobre as contagens de sinistros fatais discretizados nas faixas de 5 km. A curva quantifica a desigualdade na distribuição espacial sem assumir formas de agrupamentos predefinidos. Como métricas de concentração, extraímos a proporção de acidentes fatais acumulada nas faixas mais críticas (top 5% e 10%) e a fração mínima da malha necessária para responder por 50% dos óbitos.

4.3. Testes de Associação e Tamanho de Efeito

Para as hipóteses H1, H3 e H5, usamos o teste qui-quadrado de independência de Pearson [Pearson 1900] com correção de viés para o V de Cramér [Bergsma 2013] como medida de tamanho de efeito de variáveis categóricas. Variáveis numéricas assimétricas foram avaliadas por teste de Kruskal-Wallis [Kruskal and Wallis 1952] e tamanho de efeito ε^2 . A força da associação de fatores de traçado ou meteorológicos com óbitos foi quantificada pela Razão de Chances (OR) com IC de 95% e correção de Haldane-Anscombe. Comparações múltiplas pós-teste regional (post-hoc) foram corrigidas pelo método de Bonferroni.

5. Resultados e Discussão

Os testes estatísticos apontam para quatro frentes de ação. Cada uma traduz um padrão dos dados em uma recomendação concreta para PRF ou DNIT, com métrica de sucesso e prazo de avaliação.

5.1. Insights Acionáveis

Infraestrutura — rotatórias como prioridade de obra. Trechos com rotatória apresentam chance de acidente fatal 71% menor que os demais (OR = 0,287; IC 95% [0,246; 0,335]), o maior efeito protetor entre todos os atributos de traçado analisados. A geometria da rotatória reduz velocidade de impacto e ângulo de colisão de forma estrutural. Recomendamos que o DNIT incorpore a taxa de fatalidade por traçado como critério de priorização de obras, com foco na conversão de interseções convencionais em rotatórias nos trechos de maior concentração de ocorrências fatais. Após 24 meses, o sucesso pode ser avaliado pela variação na taxa de fatalidade nos trechos modificados, acompanhada pelo volume total de sinistros. A intervenção será bem-sucedida se a taxa cair ao menos 30% em relação à linha de base pré-obra.

Operações — efetivo concentrado nos fins de semana. Os dados mostram que fins de semana registram proporção fatal de 8,32%, contra 6,62% nos dias úteis (RR = 1,256; $p < 0,001$). A decomposição STL confirma que esse efeito é de perfil de risco, não de volume: a sazonalidade da gravidade (67,1% da variância) é independente da

sazonalidade do volume de ocorrências (38,2%). Recomendamos que a PRF redistribua parte das operações de dias úteis para o período de sexta a domingo, priorizando os trechos do top-10 de fatalidade. O resultado pode ser monitorado mensalmente pela proporção fatal nos fins de semana e será considerado positivo se essa proporção convergir para a dos dias úteis em 12 meses.

Fiscalização seletiva — trechos críticos identificados. Percebemos que 13,9% da malha rodoviária federal concentra 50% de todos os sinistros fatais do período. Os eixos BR-381 (SP), BR-116 (SP e RJ) e BR-101 (PE e SC) dominam o ranking de faixas críticas de 5 km. Isso indica que a pulverização de recursos ao longo de toda a malha é menos eficiente do que a concentração nos trechos identificados. Recomendamos que a PRF e o DNIT adotem o mapeamento de faixas críticas como instrumento de planejamento operacional e de investimento em infraestrutura. Após dois anos de atuação direcionada, o sucesso pode ser avaliado pela redução na contagem de fatais nos trechos priorizados em comparação com o período de base.

Planejamento Viário — duplicação de eixos críticos regionais. Percebemos que as regiões Norte e Nordeste concentram as maiores taxas de fatalidade (11,02% e 10,33%) devido ao predomínio de pistas simples em seus sinistros (69,9% e 55,5%). Isso sugere que a gravidade regional não é meramente comportamental, mas condicionada pela infraestrutura viária de pista única. Por isso, recomendamos que o DNIT priorize obras de duplicação nos trechos críticos das rodovias BR-101 (Nordeste) e BR-316/010 (Norte/Nordeste), integrando o planejamento de expansão com o mapeamento de faixas críticas da PRF. A decisão foi sustentada pelo teste de qui-quadrado de severidade regional ($\chi^2 = 2023,65$; $p < 0,001$) e pelo contraste de letalidade pista simples vs. dupla (9,88% vs 4,71%). Após 36 meses do início das intervenções, o sucesso pode ser avaliado pela redução na taxa de fatalidade por trecho modificado. A ação será considerada bem-sucedida se a taxa de fatalidade nas rodovias duplicadas sofrer redução de pelo menos 40% em relação à linha de base.

6. Conclusão

Este trabalho analisou 300.086 registros de sinistros em rodovias federais brasileiras (2022–2026), percorrendo limpeza de dados, engenharia de *features*, análise exploratória bivariada e verificação de cinco hipóteses por meio de testes estatísticos, decomposição temporal e análise de concentração espacial. O tipo de acidente revelou-se o preditor individual mais relevante para a gravidade (V de Cramér = 0,344); entre os atributos de traçado, rotatórias apresentam o maior efeito protetor ($OR = 0,287$), enquanto pontes e declives concentram maior risco de fatalidade.

Os resultados desafiam algumas intuições operacionais. Causas comportamentais são mais letais de dia do que à noite, o que sugere redistribuir as blitzes de sobriedade para o período diurno. Fins de semana e feriados elevam o risco, mas férias não, indicando que o problema é comportamental, não de volume. A chuva não agrava a gravidade; pelo contrário, os motoristas parecem compensar o risco reduzindo a velocidade. O espaço é desigual: 13,9% da malha concentra metade das mortes. E a infraestrutura explica a desigualdade regional: pistas simples mais que dobram a letalidade.

A principal limitação é a ausência de dados de volume de tráfego por trecho. Sem eles, as taxas refletem contagens absolutas de ocorrências, não exposição por veículo-

km rodado. A base PRF é construída a partir de boletins de atendimento, o que implica subnotificação em regiões com cobertura operacional limitada, especialmente no interior do Norte e do Nordeste. Por fim, os dados de 2026 cobrem apenas uma fração do ano, o que pode distorcer componentes sazonais se não for controlado explicitamente.

Como trabalhos futuros, recomenda-se incorporar dados de volume veicular do DNIT para calcular taxas de exposição, explorar modelos *ensemble* para capturar interações entre variáveis, e desenvolver um sistema de alerta por trecho que combine os indicadores de concentração espacial com as variáveis temporais identificadas neste trabalho.

Referências

- Bergsma, W. (2013). A bias-correction for Cramér's V and Tschuprow's T. *Journal of the Korean Statistical Society*, 42(3):323–328.
- Cleveland, R. B., Cleveland, W. S., McRae, J. E., and Terpenning, I. (1990). STL: A seasonal-trend decomposition procedure based on loess. *Journal of Official Statistics*, 6(1):3–73.
- Cohen, J. (1988). *Statistical Power Analysis for the Behavioral Sciences*. Lawrence Erlbaum Associates, 2 edition.
- Elvik, R., Høye, A., Vaa, T., and Sørensen, M. (2009). *The Handbook of Road Safety Measures*. Emerald Group Publishing, 2 edition.
- Kruskal, W. H. and Wallis, W. A. (1952). Use of ranks in one-criterion variance analysis. *Journal of the American Statistical Association*, 47(260):583–621.
- Pearson, K. (1900). On the criterion that a given system of deviations from the probable in the case of a correlated system of variables is such that it can be reasonably supposed to have arisen from random sampling. *Philosophical Magazine*, 50(302):157–175.
- Polícia Rodoviária Federal (2024a). Dados abertos — sinistros de trânsito agrupados por ocorrência. <https://www.gov.br/prf/pt-br/aceso-a-informacao/dados-abertos/dados-abertos-da-prf>. Acesso em: 2026.
- Polícia Rodoviária Federal (2024b). Dicionário de variáveis — dados abertos da prf. https://drive.google.com/file/d/1lpXLw_0D0hHVS8fiC8cv2dPX39vpuOH1/view. Acesso em: 2026.
- Shannon, C. E. (1948). A mathematical theory of communication. *The Bell System Technical Journal*, 27(3):379–423.
- Tomczak, M. and Tomczak, E. (2014). The need to report effect size estimates revisited. an overview of some recommended measures of effect size. *Trends in Sport Sciences*, 1(21):19–25.
- Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158):209–212.